

FCT - Faculdade de Ciências e Tecnologia
DMC - Departamento de Matemática e Computação
Bacharelado em Ciência da Computação

Trabalho de Conclusão de Curso
(Modalidade Trabalho Acadêmico)

Revisão bibliográfica

Aprendizado profundo na detecção de anomalias em dados ferroviários

Orientador: Prof. Dr. Cassio Machiaveli Oishi

Autor: Miguel de Campos Rodrigues Moret

Presidente Prudente, 20 de novembro de 2025

Aprendizado profundo na detecção de anomalias em dados ferroviários

Revisão bibliográfica apresentado ao curso de Ciência da Computação do Departamento de Matemática e Computação da Universidade Estadual Júlio de Mesquita Filho - Faculdade de Ciências e Tecnologia como requisito para a aprovação na disciplina de Projeto Científico I.

Aprendizado profundo na detecção de anomalias em dados ferroviários

Trabalho aprovado, Presidente Prudente, 2025:

Prof. Dr. Cassio Machiaveli Oishi

Orientador

Prof. Dr. Nome Avaliador

Convidado 1

Presidente Prudente – São Paulo

2025

RESUMO

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Nulla tempor velit enim, vitae imperdiet ligula finibus eget. Vestibulum tristique aliquet lectus sit amet fermentum. Praesent sapien eros, porttitor vitae dictum eget, posuere sed nunc. Vestibulum nec purus augue. Aliquam erat volutpat. Aenean imperdiet sapien scelerisque, sagittis mi id, cursus nisl. Integer vel arcu vitae nibh porta ultricies. Sed sem nunc, ornare lobortis maximus ornare, convallis vitae lectus. Cras vitae nunc dictum, auctor urna non, posuere felis. Donec vulputate enim magna, vitae euismod turpis pellentesque ac.

PALAVRAS-CHAVES

Palavra, Palavra, Palavra, Palavra, Palavra, Palavra, Palavra.

ABSTRACT

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Nulla tempor velit enim, vitae imperdiet ligula finibus eget. Vestibulum tristique aliquet lectus sit amet fermentum. Praesent sapien eros, porttitor vitae dictum eget, posuere sed nunc. Vestibulum nec purus augue. Aliquam erat volutpat. Aenean imperdiet sapien scelerisque, sagittis mi id, cursus nisl. Integer vel arcu vitae nibh porta ultricies. Sed sem nunc, ornare lobortis maximus ornare, convallis vitae lectus. Cras vitae nunc dictum, auctor urna non, posuere felis. Donec vulputate enim magna, vitae euismod turpis pellentesque ac.

KEYWORDS

Word, Word, Word, Word, Word, Word, Word, Word.

LISTA DE FIGURAS

1	Exemplificação de imagens presentes no dataset	10
---	--	----

SUMÁRIO

1	Introdução	8
1.1	Justificativa	8
1.2	Objetivos	8
2	Trabalhos Relacionados	9
2.1	Relação com o meu trabalho	10
3	Metodologia	10
3.1	Dataset	10
3.2	Modelos	11
3.3	Resultados Esperados	11
3.4	Avaliação dos Resultados	11
4	Referências	12

1 Introdução

1.1 Justificativa

Diante desses avanços, este trabalho concentra-se na investigação de métodos de aprendizado profundo aplicados à detecção automática de anomalias em trilhos ferroviários a partir de imagens. O objetivo é avaliar diferentes modelos, analisar seu desempenho e discutir suas potencialidades como ferramentas de apoio à manutenção preventiva da infraestrutura ferroviária. Ao reunir e analisar a literatura existente, busca-se destacar tendências, limitações e oportunidades de pesquisa, contribuindo para o desenvolvimento de soluções mais eficientes e acessíveis para o setor.

1.2 Objetivos

Sendo assim, este trabalho tem como objetivo investigar o uso de técnicas de aprendizado profundo para a detecção de anomalias em dados ferroviários, buscando desenvolver e avaliar modelos capazes de identificar automaticamente falhas estruturais em trilhos por meio de imagens. Para isso, serão conduzidas etapas de pré-processamento e análise exploratória dos dados, implementação de diferentes arquiteturas de aprendizado profundo, avaliação de desempenho por meio de métricas apropriadas e comparação dos resultados com estudos relacionados da literatura.

2 Trabalhos Relacionados

Tabela 1: Resumo de trabalhos relacionados em detecção de defeitos ferroviários

Autor / Ano	Modelo	Tipo de dado	Resultados / Observações
Karakose et al., 2017	Métodos de visão clássica	Vídeo e imagens de trilhos	Limitado por falta de dados rotulados
Szegedy et al., 2015	Inception CNN	Imagens gerais	Transfer learning para datasets pequenos
Dai et al., 2019	AlexNet, ResNet	Trilhos / fixadores	Boa generalização usando pré-treinamento
Rail-Former, 2023	Transformer semântico	Imagens de superfície de trilhos	Alta mIoU, captura detalhes pequenos
TrackNet, 2022	Vision Transformer	Trilhos de alta velocidade	Melhoria em precisão e F1, usa transfer learning
MobileViT, 2022	Compact Transformer	Imagens limitadas	Modelo leve, adequado para tempo real
EdgeViT, 2022	Compact Transformer	Imagens limitadas	Eficiência computacional em CPU ARM
CTBM-DAHD, 2023	CNN + Transformer	Arcing horns	Maior recall e precisão em alta velocidade

2.1 Relação com o meu trabalho

3 Metodologia

3.1 Dataset

O dataset inicial que será utilizado neste trabalho é o *Railway Track fault Detection Resized* (224 X 224), disponibilizado na plataforma Kaggle por Gerry. Trata-se de uma versão redimensionada do conjunto original *Railway Track Fault Detection*. Segundo o autor, as imagens possuem alta resolução, o que torna o pré-processamento custoso; por esse motivo o dataset foi recriado com todas as imagens reduzidas para 244x244x3, facilitando seu uso, também foi incluído um arquivo *rails.csv*, que simplifica o carregamento e a organização das amostras.

O conjunto contém 384 imagens de trilhos, sendo metade correspondente a trilhos defeituosos e a outra metade a trilhos em boas condições. A divisão proposta pelo autor distribui as imagens em 6% para teste, 78% para treinamento e 16% para validação.

Os defeitos representados no dataset concentram-se em três categorias: ausência de pinos de fixação, deformações na alma do trilho (parte lateral entre a)

Ele é composto por três tipos de defeitos, falta de pinos, deformações/rachaduras nos trilhos e ausência de dormentes (tábuas transversais aos trilhos)

Figura 1: Exemplificação de imagens presentes no dataset



Fonte: Gerry (adaptado)

Devido ao tamanho reduzido e à qualidade limitada do dataset, permanece em aberto a possibilidade de incorporar novos conjuntos de dados, seja para ampliar a quantidade de amostras disponíveis, seja para garantir maior diversidade visual e melhorar o desempenho dos modelos.

3.2 Modelos

3.3 Resultados Esperados

3.4 Avaliação dos Resultados

Os resultados dos modelos serão avaliados utilizando quatro métricas:

- **Acurácia** (Accuracy)

Mede a proporção de classificações corretas, sendo utilizada para analisar o desempenho dos modelos de forma geral.

$$A = \frac{CC}{CC + CI}$$

- **Precisão** (Precision)

Mede a proporção de positivos verdadeiros entre as predições positivas, sendo utilizada para avaliar o grau de confiabilidade das detecções positivas.

$$P = \frac{VP}{VP + FP}$$

- **Revocação** (Recall)

Mede a capacidade do modelo de recuperar os positivos reais, avaliando o quanto o modelo deixa de detectar casos positivos.

$$R = \frac{VP}{VP + FN}$$

- **F1-score**

Média harmônica entre precisão e revocação, resumindo ambas em uma única métrica.

$$F1 = 2 \frac{P \cdot R}{P + R}$$

Legenda das siglas:

- CC: Classificações Corretas;
- CI: Classificações Incorretas;
- VP: Verdadeiros Positivos;
- FP: Falsos Positivos;

- FN: Falsos Negativos;
- VN: Verdadeiros Negativos;

4 Referências